

Clase 18: Clase taller, scrapping con selenium.

Profesor: Pablo J Piccoli Bornia

Auxiliares: Daniela Longas M Victoria Tolosa

Selenium

Sobre selenium

Selenium es un framework para simulación de actividad en internet. El mismo tiene una librería de nombre homónimo para python.

pip install selenium

Este es el comando en terminal para instalar la librería.

La documentación es amplia, se encuentra aquí:

<https://selenium-python.readthedocs.io/>

Selenium y scraping

Hasta ahora en la materia encaramos el scrapping desde el punto de vista de parsear (recorrer y extraer datos) el código fuente de una página.

Imaginemos que queremos parsear precios de varias zapatillas que se venden en un marketplace. Podemos:

- Tener un documento con todas las páginas a parsear de antemano.
- Tener un bot que se meta publicación a publicación y extraiga el precio.

Cuál parece más lógica?

Selenium sirve para recrear el comportamiento en internet de una persona

El principal elemento de una sesión de selenium es el **WebDriver**. Instancia que simula un navegador

Sobre xpaths

XPath (XML Path Language) es un lenguaje de consulta diseñado para navegar a través de los nodos (elementos, atributos, y texto) en un documento estructurado, como XML o HTML. Funciona de manera similar a las rutas de directorios de archivos, permitiendo localizar y extraer datos específicos con gran precisión.

La manera en que usaremos selenium será inspeccionando un elemento web, extrayendo su xpath y a partir de allí manipularlo (clickearlo, pasarle un input, etc).

Los “enemigos” de selenium

Existen grandes limitantes en lo que uno puede hacer con selenium. De lo más grave a lo más “solucionable”:

- **CAPTCHA:** El botón “no soy un robot”. Básicamente la página monitorea los movimientos de nuestro cursor, los humanos dejamos una “huella errática” mientras que los bots trazan líneas perfectas. Un captcha es un game over a nuestro bot.
- **Software de detección:** Cloudflare por ejemplo. No te dejará avanzar pero modificando parámetros de nuestro webDriver tal vez puedas engañarlo.
- **Modificación de la página:** problema compartido con el scrapping “tradicional” de html y BeautifulSoup. Si modifican la página, cambian los xpath. Por esto los bots con selenium necesitan mantenimiento constante.

Objetivo de la clase

Intentar crear un bot que realice alguna acción que consideren útil:

- Sacar un turno médico.
- Reservar una cancha de F5.
- Descargar algún certificado gubernamental (certificado de CUIT, etc).
- Lo que se les ocurra.

Es muy probable que se choquen con los “enemigos” de los bots, para este ejercicio en particular pueden usar IA para guiarse + la documentación de Selenium + los .py de ejemplo