

Clase 18: Clase taller, corriendo modelos de IA

Profesor: Pablo J Piccoli Bornia

Auxiliares: Daniela Longas M Victoria Tolosa

Ollama

Instalación

De esta página se descarga el framework:

<https://ollama.com/>

Luego instalar la librería de python:

pip install ollama

Luego, para descargar modelos desde terminal se usa **ollama pull**

Ollama pull tinyllama → 0,6 GB aprox

Ollama pull llama3 (opcional) → 4,7 GB

Sobre Ollama

Ollama es una herramienta diseñada para ejecutar modelos de lenguaje (LLMs) de manera local en tu propia computadora, sin depender de servicios en la nube como OpenAI (ChatGPT) o Google (Gemini).

Esto implica que los modelos de Ollama son:

- **Privados:** todo sucede en tu compu, no estás compartiendo datos.
- **Gratis:** nada de tokens ni suscripciones.
- **Limitados:** la fuente de datos de los modelos de Ollama es el modelo mismo que descargás. El mismo fue entrenado y deployado en cierto momento y así quedó. El modelo descargado es incapaz de usar internet como fuente de datos per-se. No está constantemente re-entrenándose tampoco (como si lo hacen las IA comerciales)

Qué estás descargando al usar Ollama?

Al pullear modelos de Ollama estás descargando justamente eso: un modelo. Por dentro, estos modelos son una serie de matrices enormes que representan “conexiones” que permiten interpretar texto y generar una respuesta.

Desde un punto de vista un poco más técnico, estos modelos son **redes neuronales** contenidas dentro de archivos de extensión .gguf

Ejercicio 1: Tinyllama

Crear un agente y un script de python que le de uso a dicho agente. Explorar la limitación grande que tiene este modelo (mala performance). Pensar una situación en la cual un modelo así de básico podría servir de algo.

Ejercicio 2: llama3 (opcional)

Si te decidís a gastar 4,7GB de almacenamiento en bajarte llama3, recrear el script de ejemplo pero agregando más agentes y creando una mini-obra de teatro.

Ej:

- 3 agentes: 2 jugadores de futbol que discuten y un referi que solo interviene si hay agresión entre ellos.
- 4 agentes: 4 personas que están jugando una partida de Catan.
- 6 agentes: Milei, Lula, Kast, Orsi, Peña y Paz-Pereira discutiendo el destino del Cono Sur.